

清华大学

大学数学实验

大学数学实验

实验7 无约束优化

清华大学数学科学系

清华大学

大学数学实验

优化模型和算法的重要意义

最优化：在一定条件下，寻求使目标最大(小)的**决策**

最优化是工程技术、经济管理、科学研究、社会生活中经常遇到的问题, 如:

结构设计 资源分配 生产计划 运输方案

解决**决策**问题的手段

- 经验积累, 主观判断
- 作试验, 比优劣
- 建立数学模型, 求解最优策略

清华大学

大学数学实验

(最)优化理论是运筹学的基础

OR/

MS/

DS

运筹学(OR: Operations/Operational Research)

管理科学(MS: Management Science)

决策科学 (DS: Decision Science)

优化(Optimization), 规划(Programming)

无约束优化

线性规划

非线性规划

整数规划

组合优化

不确定规划

多目标规划

目标规划

网络优化

动态规划

清华大学

大学数学实验

数学规划的一般形式

$$\min_x z = f(x), x \in \Omega \subseteq R^n$$

$x \sim$ 决策变量, $f \sim$ 目标函数, $\Omega \sim$ 可行域

$$\min_x z = f(x) \quad (1)$$

$$s.t. g_i(x) \leq 0, i = 1, 2, \dots, m \quad (2)$$

- 可行解 (只满足(2)) 与最优解 (满足(1),(2))
- 无约束优化 (只有(1)) 与约束优化 ((1),(2))
- 实际问题一般总有约束, 何时可用无约束优化处理?

清华大学

大学数学实验

无约束优化的主要内容

1. 优化问题的最优解条件; 算法模式
2. 无约束优化的基本方法:

梯度法, 牛顿法, 拟牛顿法
3. 线性、非线性最小二乘法
4. 优化工具箱的使用
5. 实际问题中的无约束优化模型

清华大学

大学数学实验

实例1 产销量安排

某厂生产两个牌号的同一种产品, 如何确定产量使利润最大

牌号	产量	成本	价格
甲	x_1	q_1	p_1
乙	x_2	q_2	p_2

假设A

产销平衡

假设B

p 随 x (两种牌号)增加而减小, 呈线性关系

$$p_1 = b_1 - a_{11}x_1 - a_{12}x_2, b_1, a_{11}, a_{12} > 0, a_{11} > a_{12}$$

$$p_2 = b_2 - a_{21}x_1 - a_{22}x_2, b_2, a_{21}, a_{22} > 0, a_{22} > a_{21}$$

清华大学 大学数学实验

实例1 产销量安排

假设C q 随 x (本牌号)增加而减小, 呈负指数关系

$$q_1 = r_1 e^{-\lambda_1 x_1} + c_1, \quad r_1, \lambda_1, c_1 > 0$$

$$q_2 = r_2 e^{-\lambda_2 x_2} + c_2, \quad r_2, \lambda_2, c_2 > 0$$

目标 利润最大

$$\max_{x_1, x_2} z(x_1, x_2) = (p_1 - q_1)x_1 + (p_2 - q_2)x_2$$

清华大学 大学数学实验

实例2 饮酒驾车血液中的酒精含量 (续)

已建模型 由实验1: 酒精含量 $c(t)$ 随时间 t 的变化规律

$$c(t) = c_0 e^{-kt} \quad y = \ln c(t), \quad a_1 = -k, \quad a_2 = \ln c_0$$

$$y = a_1 t + a_2$$

实际数据

t	1	2	3	4	5	6	7	8	9	10	11	12
$c(t)$	82	77	68	51	41	38	35	28	25	18	15	12

$$y_i = a_1 t_i + a_2, \quad i = 1, 2, \dots, n.$$

方程个数超过了未知数个数, 称为**超定方程组**

在普通意义下一般无解, 需要在**新的准则**下定义它的解

清华大学 大学数学实验

超定方程组与曲线拟合

由已知数据计算已知函数关系中的系数, 称为**数据拟合 (或曲线拟合, curve fitting)**

数据(曲线)拟合问题的一般提法

已知一组数据 $(t_i, y_i), i=1, \dots, n$, 寻求一个函数 (曲线) $y=f(t)$, 使 $f(t)$ 在某种准则下与所有数据点最为接近, 即曲线拟合得最好。

当函数/曲线的形式确定后, 待定系数 \rightarrow **超定方程组**

清华大学 大学数学实验

曲线拟合与最小二乘准则

使点 (t_i, y_i) 与曲线 $y=f(t)$ 的距离 r_i 尽量小, $i=1, \dots, n$; 记 $r=(r_1, r_2, \dots, r_n)$

使 $f(t_i)$ 与 y_i 之差的平方和 (即图中 r_i 的平方和) 最小, 称为 **最小二乘 (Least Square) 准则** (等价于 r 的2-范数最小)

对实例2:
$$\min_{a_1, a_2} \sum_{i=1}^{12} |a_1 t_i + a_2 - y_i|^2$$

其他准则: 最小化 r_i 的绝对值的和 (r 的1-范数)

最小化 r_i 中的最大者 (r 的 ∞ -范数)

清华大学 大学数学实验

线性最小二乘拟合的基本思路

先选定一组**基函数** $\varphi_0(t), \varphi_1(t), \dots, \varphi_m(t), m+1 \leq n$, 令

$$f(t) = \beta_0 \varphi_0(t) + \beta_1 \varphi_1(t) + \dots + \beta_m \varphi_m(t)$$

$$f(t_i) = y_i \quad (i=1, \dots, n) \Rightarrow \begin{cases} \beta_0 \varphi_0(t_1) + \beta_1 \varphi_1(t_1) + \dots + \beta_m \varphi_m(t_1) = y_1 \\ \dots \\ \beta_0 \varphi_0(t_n) + \beta_1 \varphi_1(t_n) + \dots + \beta_m \varphi_m(t_n) = y_n \end{cases}$$

$$\Phi = \begin{bmatrix} \varphi_0(t_1) & \varphi_1(t_1) & \dots & \varphi_m(t_1) \\ \dots & \dots & \dots & \dots \\ \varphi_0(t_n) & \varphi_1(t_n) & \dots & \varphi_m(t_n) \end{bmatrix} \quad \beta = (\beta_0, \beta_1, \dots, \beta_m)^T$$

$$y = (y_1, \dots, y_n)^T$$

$$\Rightarrow \Phi \beta = y \quad \Rightarrow \min_{\beta} \sum_{i=1}^n r_i^2 = \sum_{i=1}^n |f(t_i) - y_i|^2 = \|\Phi \beta - y\|_2^2$$

清华大学 大学数学实验

实例3 飞机精确定位问题

飞机与监控台 (图中坐标和测量距离的单位是“公里”)

飞机精确定位模型

已知数据：设备位置坐标分别为 $(x_i, y_i), i=1, \dots, 4$;
记测量角度为 θ_i , 角度误差为 $\sigma_i, i=1, \dots, 3$;
记测量距离为 d_4 , 距离误差为 σ_4 .

要求计算：飞机位置坐标 (x, y)

不考虑误差因素 **量纲不符!**

$$\text{atan2}(x - x_i, y - y_i) = \theta_i \quad \text{超定方程组,}$$

$$\sqrt{(x - x_4)^2 + (y - y_4)^2} = d_4 \quad \text{非线性最小二乘!}$$

→ $\text{Min}_{x,y} \sum_{i=1}^3 \left(\frac{\text{atan2}(x - x_i, y - y_i) - \theta_i}{\sigma_i} \right)^2 + \left(\frac{\sqrt{(x - x_4)^2 + (y - y_4)^2} - d_4}{\sigma_4} \right)^2$

飞机精确定位模型

考虑误差因素 **误差非均匀分布!**

$$\theta_i - \sigma_i \leq \text{atan2}(x - x_i, y - y_i) \leq \theta_i + \sigma_i \quad ?$$

$$d_4 - \sigma_4 \leq \sqrt{(x - x_4)^2 + (y - y_4)^2} \leq d_4 + \sigma_4 \quad \text{非线性规划}$$

Min x ; Min y ; Max x ; Max y .

有人也可能会采用其他目标，如：
以距离为约束，优化角度误差之和（或平方和）；
或以角度为约束，优化距离误差。

仅部分考虑误差!
角度与距离的“地位”不应不同!

飞机精确定位模型

误差一般服从什么分布？ 不同的量纲如何处理？
正态分布！ 归一化处理！

Min $E(x, y) =$ **无约束非线性最小二乘模型**

$$\sum_{i=1}^3 \left(\frac{\text{atan2}(x - x_i, y - y_i) - \theta_i}{\sigma_i} \right)^2 + \left(\frac{d_4 - \sqrt{(x - x_4)^2 + (y - y_4)^2}}{\sigma_4} \right)^2$$

角度需要进行预处理，
如利用atan2函数，值域 $(-\pi, \pi)$

多选题 2分

根据本教材的观点，数学规划模型的三要素是：

- ☐ A 模型是最大化问题还是最小化问题
- ☒ B 目标函数
- ☒ C 决策变量
- ☐ D 模型的参数
- ☒ E 约束条件
- ☐ F 模型是连续优化还是离散优化

提交

无约束优化:最优解的分类和条件

给定一个函数 $f(x)$, 寻找 x^* 使得 $f(x^*)$ 最小, 即

$$\text{Min}_x f(x) \quad \text{其中 } x = (x_1, x_2, \dots, x_n)^T \in \mathbb{R}^n$$

局部最优解 **全局最优解**

↓

必要条件 $\nabla f(x^*) = (f_{x_1}, \dots, f_{x_n})^T = 0$

充分条件 $\nabla f(x^*) = 0, \nabla^2 f(x^*) > 0 \quad \nabla^2 f = \left[\frac{\partial^2 f}{\partial x_i \partial x_j} \right]_{n \times n}$

Hessian阵

多选题 2分

关于无约束极小化问题的解法，下列说法正确的是

- ☐ A 一般采用直接法求解
- ☒ B 一般采用迭代法求解
- ☐ C 迭代法一般先确定搜索步长，再确定搜索方向
- ☒ D 迭代法一般先确定搜索方向，再确定搜索步长
- ☐ E 最速下降法是收敛最快的迭代法

提交

大学数学实验

求解无约束优化的基本思路

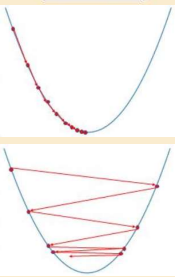
在 \mathcal{R}^n 中某一点, 确定一个搜索方向及沿该方向步长 \rightarrow 使目标函数下降的新点

迭代步骤

Step 1 初始化: 初始点 x^0 , 终止准则等

Step 2 迭代改进: 方向 d^k , 步长 α^k
 $x^{k+1} = x^k + \alpha^k d^k$
 $f(x^{k+1}) < f(x^k)$ (下降法, 下山法)

Step 3 终止检验: 得到近优解或 $k+1 \Rightarrow k$ 转2
 选择 d^k, α^k 使 f 下降更快 \Rightarrow 不同算法



大学数学实验

搜索方向的选择

1 最速下降法 (梯度法) 暂不考虑搜索步长, 可设 $\alpha^k=1$

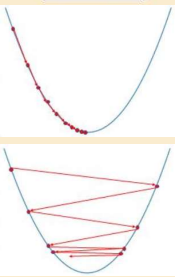
将 $f(x^{k+1})$ 在 x^k 点作泰勒展开, 只保留一阶项, 有
 $f(x^{k+1}) = f(x^k + d^k) = f(x^k) + \nabla f^T(x^k) d^k$

下降方向 $\nabla f^T(x^k) d^k < 0$

最速下降方向 $d^k = -\nabla f(x^k)$ (负梯度方向)

迭代改进格式 $x^{k+1} = x^k - \nabla f(x^k)$

算法特点 初始阶段改进较快, 最优解附近改进较慢
 (“最速”: 局部性质) (“锯齿现象”)



大学数学实验

2 Newton方法

将 $f(x^{k+1})$ 在 x^k 点作泰勒展开至二阶项, 用 d 替代 d^k

$$f(x^{k+1}) = f(x^k + d) = f(x^k) + \nabla f^T(x^k) d + \frac{1}{2} d^T \nabla^2 f(x^k) d$$

求 d 使 $f(x^{k+1})$ 极小 \Rightarrow 右端对 d 导数为0 $\Rightarrow \nabla f(x^k) + \nabla^2 f(x^k) d = 0$

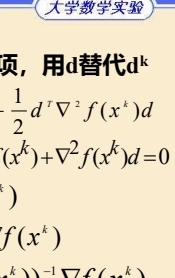
牛顿方程 $\nabla^2 f(x^k) d = -\nabla f(x^k)$

牛顿方向 $d^k = -(\nabla^2 f(x^k))^{-1} \nabla f(x^k)$

迭代格式 $x^{k+1} = x^k - (\nabla^2 f(x^k))^{-1} \nabla f(x^k)$

特点 局部2阶收敛; 需计算Hessian阵, 它可能病态或不正定

比较 解 $F(x) = 0$ 的牛顿法 $x^{k+1} = x^k - [F'(x^k)]^{-1} F(x^k)$
 $F(x) \Leftrightarrow \nabla f(x)$



大学数学实验

3 拟Newton方法

目的 不计算Hessian阵, 克服病态、不正定、计算复杂等缺陷, 同时保持收敛较快的优点

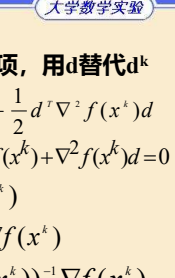
思路 回顾解方程组 $F(x)=0$ 的拟牛顿法

$$x^{k+1} = x^k - [F'(x^k)]^{-1} F(x^k) \quad \square \rightarrow \quad x^{k+1} = x^k - (A^k)^{-1} F(x^k)$$

使 A^k 满足 $A^k(x^k - x^{k-1}) = F(x^k) - F(x^{k-1})$

用迭代方法 $A^k = A^{k-1} + \Delta A^{k-1}$ 计算 A^k

优化问题 $\min_x f(x)$ $\nabla f(x)$ 相当 $F(x)$
 $\nabla^2 f(x)$ 相当 $F'(x)$, $\nabla^2 f$ 不一定正定, 构造正定阵 G 代替 $\nabla^2 f$



大学数学实验

3 拟Newton方法(续)

设在第 k 步, G^k 已得到, $H^k = (G^k)^{-1}$, 可计算
 $x^{k+1} = x^k - H^k \nabla f(x^k)$

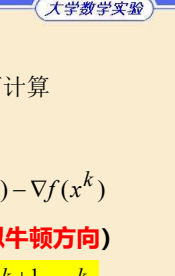
记 $\Delta x^k = x^{k+1} - x^k$, $\Delta f^k = \nabla f(x^{k+1}) - \nabla f(x^k)$

G^{k+1} 满足 **拟牛顿条件**: (相应的方向称 **拟牛顿方向**)

$G^{k+1} \Delta x^k = \Delta f^k$ 或 $\Delta x^k = H^{k+1} \Delta f^k$

构造迭代公式 $G^{k+1} = G^k + \Delta G^k$ 或 $H^{k+1} = H^k + \Delta H^k$

于是有 $x^{k+2} = x^{k+1} - H^{k+1} \nabla f(x^{k+1})$



大学数学实验

3 拟Newton方法(续)

3.1 Davidon-Fletcher-Powell (DFP) 公式

$$\Delta H^k = \frac{\Delta x^k (\Delta x^k)^T}{(\Delta x^k)^T \Delta f^k} - \frac{H^k \Delta f^k (\Delta f^k)^T H^k}{(\Delta f^k)^T H^k \Delta f^k}$$

$$\Delta G^k = (1 + \frac{(\Delta x^k)^T G^k \Delta x^k}{(\Delta x^k)^T \Delta f^k}) \frac{\Delta f^k (\Delta f^k)^T}{(\Delta x^k)^T \Delta f^k} - \frac{\Delta f^k (\Delta x^k)^T G^k + G^k \Delta x^k (\Delta f^k)^T}{(\Delta x^k)^T \Delta f^k}$$

3.2 Broyden-Fletcher-Goldfarb-Shanno (BFGS) 公式

$$\Delta G^k = \frac{\Delta f^k (\Delta f^k)^T}{(\Delta f^k)^T \Delta x^k} - \frac{G^k \Delta x^k (\Delta x^k)^T G^k}{(\Delta x^k)^T G^k \Delta x^k}$$

$$\Delta H^k = (1 + \frac{(\Delta f^k)^T H^k \Delta f^k}{(\Delta x^k)^T \Delta f^k}) \frac{\Delta x^k (\Delta x^k)^T}{(\Delta x^k)^T \Delta f^k} - \frac{\Delta x^k (\Delta f^k)^T H^k + H^k \Delta f^k (\Delta x^k)^T}{(\Delta x^k)^T \Delta f^k}$$


多选题 2分

关于无约束极小化问题的解法，下列说法正确的是

- ☒ A 最速下降法就是梯度(下降)法
- ☐ B 最速下降法是收敛速度最快的算法
- ☐ C 最速下降法是牛顿法的特例
- ☐ D 拟牛顿法是牛顿法的特例
- ☐ E 以上都不对

提交

搜索步长的确定

一维搜索 (线搜索, Line Search) 确定步长的方法

问题 给定 x^k 和方向 d^k , 确定步长 $\alpha^k > 0$ 使得

$$\min_{\alpha} f(x^k + \alpha d^k) \sim \text{一维优化问题}$$

优化算法 $\phi(\alpha) = f(x^k + \alpha d^k)$

(精确线搜索) $\phi(\alpha^k) = \min \phi(\alpha)$

$$\left. \frac{df}{d\alpha} \right|_{\alpha^k} = 0 \iff (d^k)^T \nabla f(x^k + \alpha^k d^k) = 0$$

非精确线搜索: α^k 使函数值下降一个可接受量即可 (例如: Wolfe 准则; Armijo 准则) ---- 略去

精确线搜索(Line Search) $\min_{\alpha} f(x^k + \alpha d^k)$

黄金分割(0.618)法、Fibonacci法、Newton切线法、割线法、2次(抛物线)或3次多项式插值法等

- 通常先确定搜索区间 $[a, b]$ (bracketing phase)
- 例如 进退法 (下页)
- 找到“高-低-高”三个点
- 然后精细搜索 (sectioning phase)

单峰(unimodal)函数; 单谷函数

搜索区间: 进退法 (示意)

搜索区间: 进退法

步1 初值: 选取 $a_0 \geq 0, h_0 > 0$. 计算 $\phi_0 := \phi(a_0)$. 置 $k := 0$.

步2 令 $a_{k+1} = a_k + h_k$, 计算 $\phi_{k+1} = \phi(a_{k+1})$. 若 $\phi_{k+1} \leq \phi_k$, 转步3, 否则转步4.

步3 加大步长. 令 $h_{k+1} = \tau h_k, a = a_k, a_k = a_{k+1}, \phi_k = \phi_{k+1}, k = k+1$, 转步2. (τ 常取 2)

步4 反向搜索或输出. 若 $k=0$, 令 $h_1 = -h_0, a_1 = a_0, \phi_1 = \phi_0, k=1$, 转步2; 否则停止迭代, 令 $a = \min\{a, a_{k+1}\}, b = \max\{a, a_{k+1}\}$.

投票 最多可选1项

已知单变量连续函数 $f(x)$ 在 (a, b) 区间端点取值异号, 求 $f(x)=0$ 在 (a, b) 区间上的根, 0.618法与二分法相比, 你觉得哪个更好?

- ☐ A 0.618法
- ☐ B 二分法
- ☐ C 不分伯仲
- ☐ D 我不知道, 不能草率下结论

提交

大学数学实验

非线性方程的基本解法

0.618法 (黄金分割法?)

假设概率各为1/2(不太合理), 则区间长度缩短
期望值: $\tau^* 1/2 + (1-\tau) * 1/2 = 1/2$

假设零点均匀分布, 则区间长度缩短
期望值: $\tau^2 + (1-\tau)^2 \gg 1/2$ (二分法更好)

大学数学实验

线搜索的黄金分割法(0.618法)

针对单峰(单谷)函数

缩短率

$$b_k - \lambda_k = \mu_k - a_k, \quad \frac{1}{2} < \tau_k < 1(1)$$

$$b_{k+1} - a_{k+1} = \tau_k (b_k - a_k)$$

$$\mu_k - a_k = \tau_k (b_k - a_k) \quad \mu_k = a_k + \tau_k (b_k - a_k) \quad (2)$$

$$b_k - \lambda_k = \tau_k (b_k - a_k) \quad \lambda_k = a_k + (1 - \tau_k)(b_k - a_k) \quad (3)$$

且下次迭代时, $[a_{k+1}, b_{k+1}]$ 区间内旧点仍可利用!

大学数学实验

三次插值法 (Matlab中使用)

Davidon (1959) 提出

先找区间 $[a, b]$: $a < b$, $F'(a) < 0$, $F'(b) > 0$

用 a, b 两点的函数值、导数值, 得插值 $P(\alpha)$
(三次Hermite插值)

这里 F 表示 ϕ

$$P(\alpha) = a_1 (\alpha - \alpha^{(0)})^3 + a_2 (\alpha - \alpha^{(0)})^2 + a_3 (\alpha - \alpha^{(0)}) + a_4, \quad (1)$$

通常取 $\alpha^{(0)} = a$, 则 $a_4 = F(a)$, $a_3 = F'(a)$

大学数学实验

三次插值法 (Matlab中使用)

$$P(\alpha) = a_1 (\alpha - \alpha^{(0)})^3 + a_2 (\alpha - \alpha^{(0)})^2 + a_3 (\alpha - \alpha^{(0)}) + a_4, \quad (1)$$

$$a_4 = F(a), a_3 = F'(a) \quad F(b) = P(b), F'(b) = P'(b)$$

$$a_1 = \frac{(b-a)[F'(b) + F'(a)] + 2[F(a) - F(b)]}{(b-a)^3}$$

$$a_2 = \frac{3[F(b) - F(a)] - (b-a)[F'(b) + 2F'(a)]}{(b-a)^2}$$

求解 $P'(\alpha) = 0$ (两根), 并要求 $P''(\alpha) > 0$, 直接得到

$$\alpha^* = \alpha^{(0)} - \frac{a_3}{a_2 + \sqrt{a_2^2 - 3a_1 a_3}}$$

当 $a_1 = 0$: 退化成书上的二次(抛物线)插值

多选题 2分

关于无约束极小化问题的解法, 下列说法正确的是

- ☐ A 一般采用直接法求解
- ☒ B 一般采用迭代法求解
- ☐ C 迭代法一般先确定搜索步长, 再确定搜索方向
- ☒ D 迭代法一般先确定搜索方向, 再确定搜索步长
- ☐ E 最速下降法是收敛最快的迭代法

提交

大学数学实验

超定方程组与曲线拟合

由已知数据计算已知函数关系中的系数,
称为数据拟合(或曲线拟合, curve fitting)

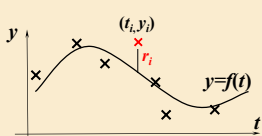
数据(曲线)拟合问题的一般提法

已知一组数据 $(t_i, y_i), i=1, \dots, n$, 寻求一个函数(曲线)
 $y=f(t)$, 使 $f(t)$ 在某种准则下与所有数据点最为接近, 即
曲线拟合得最好。

当函数/曲线的形式确定后, 待定系数 \rightarrow 超定方程组

清华大学 大学数学实验

曲线拟合与最小二乘准则



使点 (t_i, y_i) 与曲线 $y=f(t)$ 的距离 r_i 尽量小, $i=1, \dots, n$;
记 $r=(r_1, r_2, \dots, r_n)$

使 $f(t_i)$ 与 y_i 之差的平方和 (即图中 r_i 的平方和) 最小, 称为 **最小二乘 (Least Square) 准则** (等价于 r 的 2-范数最小)

对实例 2:
$$\min_{a_1, a_2} \sum_{i=1}^n |a_1 t_i + a_2 - y_i|^2$$

其他准则: 最小化 r_i 的绝对值的和 (r 的 1-范数)
最小化 r_i 中的最大者 (r 的 ∞ -范数)

清华大学 大学数学实验

线性最小二乘拟合的基本思路

先选定一组 **基函数** $\varphi_0(t), \varphi_1(t), \dots, \varphi_m(t)$, $m+1 < n$, 令

$$f(t) = \beta_0 \varphi_0(t) + \beta_1 \varphi_1(t) + \dots + \beta_m \varphi_m(t)$$

$$f(t_i) = y_i \quad (i=1, \dots, n) \Rightarrow \begin{cases} \beta_0 \varphi_0(t_1) + \beta_1 \varphi_1(t_1) + \dots + \beta_m \varphi_m(t_1) = y_1 \\ \dots \\ \beta_0 \varphi_0(t_n) + \beta_1 \varphi_1(t_n) + \dots + \beta_m \varphi_m(t_n) = y_n \end{cases}$$

$$\Phi = \begin{bmatrix} \varphi_0(t_1) & \varphi_1(t_1) & \dots & \varphi_m(t_1) \\ \dots & \dots & \dots & \dots \\ \varphi_0(t_n) & \varphi_1(t_n) & \dots & \varphi_m(t_n) \end{bmatrix} \quad \begin{aligned} \beta &= (\beta_0, \beta_1, \dots, \beta_m)^T \\ y &= (y_1, \dots, y_n)^T \end{aligned}$$

$$\Rightarrow \Phi \beta = y \quad \Rightarrow \min_{\beta} \sum_{i=1}^n r_i^2 = \sum_{i=1}^n |f(t_i) - y_i|^2 = \|\Phi \beta - y\|_2^2$$

清华大学 大学数学实验

线性最小二乘法: 求解

$$J(\beta_0, \beta_1, \dots, \beta_m) = \|\Phi \beta - y\|_2^2 = \sum_{i=1}^n [f(t_i) - y_i]^2 = \sum_{i=1}^n \left[\sum_{k=0}^m \beta_k \varphi_k(t_i) - y_i \right]^2$$

$$\frac{\partial J}{\partial \beta_k} = 0 \quad (k=1, \dots, m) \Rightarrow \begin{cases} \sum_{i=1}^n \varphi_0(t_i) [\sum_{k=0}^m \beta_k \varphi_k(t_i) - y_i] = 0 \\ \sum_{i=1}^n \varphi_1(t_i) [\sum_{k=0}^m \beta_k \varphi_k(t_i) - y_i] = 0 \\ \dots \\ \sum_{i=1}^n \varphi_m(t_i) [\sum_{k=0}^m \beta_k \varphi_k(t_i) - y_i] = 0 \end{cases}$$

$$\Phi = \begin{bmatrix} \varphi_0(t_1) & \varphi_1(t_1) & \dots & \varphi_m(t_1) \\ \dots & \dots & \dots & \dots \\ \varphi_0(t_n) & \varphi_1(t_n) & \dots & \varphi_m(t_n) \end{bmatrix} \quad \Phi^T \Phi \beta = \Phi^T y \Rightarrow \beta = (\Phi^T \Phi)^{-1} \Phi^T y$$

清华大学 大学数学实验

线性最小二乘法: 思考

$$\Phi = \begin{bmatrix} \varphi_0(t_1) & \varphi_1(t_1) & \dots & \varphi_m(t_1) \\ \dots & \dots & \dots & \dots \\ \varphi_0(t_n) & \varphi_1(t_n) & \dots & \varphi_m(t_n) \end{bmatrix} \quad \begin{aligned} \Phi^T \Phi \beta &= \Phi^T y \\ \beta &= (\Phi^T \Phi)^{-1} \Phi^T y \end{aligned}$$

问题 1 怎样选择 $\{\varphi_0(t), \dots, \varphi_m(t)\}$, 以保证系数 $\{\beta_0, \dots, \beta_m\}$ 有唯一解?

分析 $\{\beta_0, \dots, \beta_m\}$ 有唯一解 $\leftarrow \Phi^T \Phi$ 可逆 $\leftarrow \text{Rank}(\Phi^T \Phi) = m+1$
 $\leftarrow \text{Rank}(\Phi) = m+1$ $\leftarrow \Phi$ 列满秩
 $\leftarrow \{\varphi_0(t), \dots, \varphi_m(t)\}$ 在 t_i 点线性无关 ($i=1, \dots, n$)

清华大学 大学数学实验

问题 2 为什么要规定 $m+1 < n$?

分析 强令 $f(t_i) = \beta_0 \varphi_0(t_i) + \dots + \beta_m \varphi_m(t_i) = y_i$ ($i=1, \dots, n$)
 (即曲线 $f(t)$ 过全部数据点, 此时 $J=0$) 得

$$\Phi \beta = y, \quad \Phi = \begin{bmatrix} \varphi_0(t_1) & \dots & \varphi_m(t_1) \\ \dots & \dots & \dots \\ \varphi_0(t_n) & \dots & \varphi_m(t_n) \end{bmatrix} \quad \begin{aligned} \beta &= [\beta_0, \dots, \beta_m]^T \\ y &= [y_1, \dots, y_n]^T \end{aligned}$$

若 $m+1 > n$, β 一般有无穷多解
 若 $m+1 = n$, Φ 可逆时 β 有唯一解
 若 $m+1 < n$, **超定方程组**, β 一般无解; 求 **最小二乘解**

问题 3 线性最小二乘中的“线性”指的是什么?
 $f(t)$ 对 β 线性, 于是求解线性方程组 $(\Phi^T \Phi) \beta = \Phi^T y$

清华大学 大学数学实验

非线性最小二乘拟合

问题 给定 (t_i, y_i) , $i=1, \dots, n$, 拟合一个函数 $y=f(x, t)$, 其中 x 为待定的参数向量, f 对 x 非线性。

记误差 $r_i(x) = f(x, t_i) - y_i$ $r(x) = (r_1(x), \dots, r_n(x))^T$

优化模型
$$\min_x R(x) = \frac{1}{2} r^T(x) r(x)$$

根据目标函数是 $r(x)$ 的二次函数的特点
构造简单算法

注: 非线性最小二乘拟合也可用来求 **非线性超定方程组** 的最小二乘解 (只需要将方程组看成这里的 $r(x)=0$)

非线性最小二乘拟合 $R(x) = \frac{1}{2} r^T(x) r(x)$

记 $r(x)$ 的雅各比阵为 $J(x) = (\partial r_i / \partial x_j)_{n \times m}$

$\nabla R = J(x)^T r(x) \quad \nabla^2 R = J(x)^T J(x) + S$

$S = \sum_{i=1}^n r_i(x) \nabla^2 r_i(x) \quad \nabla^2 r_i(x) = (\partial^2 r_i / \partial x_k \partial x_l)_{m \times m}$

讨论 • 牛顿法要计算Hessian矩阵, 其中S计算量大
• 若 f 对 x 线性, 则化为线性最小二乘拟合, 此时 $S=0$
特定算法考虑如何忽略或近似矩阵 S 。

非线性最小二乘拟合

Gauss-Newton算法: 忽略矩阵 S

$\nabla R = J(x)^T r(x) \quad \nabla^2 R = J(x)^T J(x)$

牛顿方程 $\nabla^2 f(x^k) d = -\nabla f(x^k)$

f 用 R 代替, 下降方向 d^k 满足

$J(x^k)^T J(x^k) d^k = -J(x^k)^T r(x^k)$

G-N算法 收敛性依赖 f 对 x 的线性程度, 及偏差 r 的大小

非线性最小二乘拟合

Levenberg-Marquardt算法: G-N算法修正

$J(x^k)^T J(x^k) d^k = -J(x^k)^T r(x^k)$

防止 $J^T J$ 出现病态

$(J(x^k)^T J(x^k) + \alpha^k I) d^k = -J(x^k)^T r(x^k)$

其中 $\alpha^k > 0$ 为修正参数。

L-M算法 d^k 位于牛顿方向 (α^k 很小) 和负梯度方向 (α^k 很大) 之间

拟合函数形式的选取

1. 通过机理分析建立数学模型来确定 $f(t)$: $f(x, t)$ 或 $f(\beta, t)$

2. 将数据 $(t_i, y_i) \quad i=1, \dots, n$ 作图, 通过直观判断确定 $f(t)$

$f = x_0 + x_1 t$

$f = x_0 + x_1 t + x_2 t^2 \quad (x_2 > 0)$

$f = x_0 + x_1 t + x_2 t^2 \quad (x_2 < 0)$

$f = x_0 + x_1 / t$

$f = x_0 \exp(x_1 t) \quad (x_1 > 0)$

$f = x_0 \exp(x_1 t) \quad (x_1 < 0)$

f 对 a 非线性, 但可线性化

多选题 2分

给定 $(t_i, y_i), i=1, \dots, n$, 用最小二乘法拟合一个函数 $y=f(x, t)$, 其中 x 为待定的参数向量。下列说法正确的是:

A 最小二乘法的目标是使 n 个点上的误差的绝对值之和最小

B 最小二乘法的目标是使 n 个点上的误差的平方和最小

C 当 f 关于 x 是线性函数时称为线性最小二乘法

D 当 f 关于 t 是线性函数时称为线性最小二乘法

提交

用MATLAB解无约束优化

模型: $\min_x f(x), x \in R^n$

$f.m \sim f(x)$ 的 m 文件名

$x_0 \sim$ 初始点; $x \sim$ 最优解

基本用法:

$x = \text{fminbnd}(@f, lb, ub)$

$x = \text{fminunc}(@f, x_0)$

$x = \text{fminunc}(@f, x_0, options)$

$x = \text{fminsearch}(@f, x_0, options)$

例1: $\min (3\sin x + x)$
 $x \in [1, 8]$

例2: $\min \frac{x^2}{a} + \frac{y^2}{b}$
其中 $a = b = 2$

Exam0701.m

Exam0702.m

清华大学 大学数学实验

用MATLAB解无约束优化

fminbnd	←	'golden section search, parabolic interpolation'
fminsearch	←	'Nelder-Mead simplex direct search'
fminunc	←	'quasi-newton' (default) or 'trust-region'

- 'bfgs', the default
- 'dfp'
- 'steepdesc' (梯度法)

清华大学 大学数学实验

非线性最小二乘法

$$\min_{lb \leq x \leq ub} R(x) = r^T(x)r(x) \quad r_i(x) = f(x, t_i) - y_i \quad r(x) = (r_1(x), \dots, r_n(x))^T$$

```
[x, resnorm, res, exitf, out, lambda, jacob] =
lsqcurvefit(@f, x0, t, y, lb, ub, options)
[x, resnorm, res, exitf, out, lambda, jacob] =
lsqnonlin(@fun, x0, lb, ub, options)
```

输入的用法与fminunc类似, 但注意:

f.m~f(x)的m文件名: function y=f(x, t)

fun.m~r(x)的m文件名: function r=fun(x, t, y)

输出 resnom=r(x)^T*r(x), res=r(x) (误差向量)

多选题 2分 设置

关于Matlab的优化求解器, 以下说法正确的是

☐ A fminbnd 适合于最多10个决策变量的问题

☒ B fminsearch 适合于目标函数不连续的问题

☒ C fminsearch 可以求解有多个决策变量的问题

☐ D fminunc 优于 fminbnd 和 fminsearch

☐ E 以上都不对

提交

清华大学 大学数学实验

非线性最小二乘法

$$\min_{lb \leq x \leq ub} R(x) = r^T(x)r(x)$$

例3 用下面一组数据拟合系数 k : $c(t) = re^{-kt}$

t	0.25	0.5	1	1.5	2	3	4	6	8
c	19.21	18.15	15.36	14.10	12.89	9.32	7.45	5.24	3.01

exam0703fit.m exam0703lsq.m

清华大学 大学数学实验

实例1 产销量安排

原问题

$$p_i = b_i - a_{i1}x_1 - a_{i2}x_2, \quad b_i, a_{i1}, a_{i2} > 0, \quad i=1,2,$$

$$q_i = r_i e^{-\lambda_i x_i} + c_i, \quad r_i, \lambda_i, c_i > 0, \quad i=1,2,$$

$$\max_{x_1, x_2} z(x_1, x_2) = (p_1 - q_1)x_1 + (p_2 - q_2)x_2$$

已知数据

$$\begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix} = \begin{pmatrix} 1 & 0.1 \\ 0.2 & 2 \end{pmatrix} \quad b = \begin{pmatrix} 100 \\ 280 \end{pmatrix}$$

$$r^T = (30 \quad 100), \quad \lambda^T = (0.015 \quad 0.02), \quad c^T = (20 \quad 30)$$

$$\min f(x) = -(b_1 - a_{11}x_1 - a_{12}x_2 - r_1 e^{-\lambda_1 x_1} - c_1)x_1 - (b_2 - a_{21}x_1 - a_{22}x_2 - r_2 e^{-\lambda_2 x_2} - c_2)x_2$$

清华大学 大学数学实验

实例1 产销量安排

初始点的选择

忽略成本及价格中的 a_{12}, a_{21}

$$\begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix} = \begin{pmatrix} 1 & 0.1 \\ 0.2 & 2 \end{pmatrix}$$

问题简化为

$$\min f(x) = -(b_1 - a_{11}x_1)x_1 - (b_2 - a_{22}x_2)x_2$$

其解为 $x_1 = b_1 / 2a_{11} = 50, \quad x_2 = b_2 / 2a_{22} = 70$

作为原问题的初始点

命令和最优解

```
x=fminunc(@f, x0)
```

shili0701.m

x = 23.9025 62.4977 y = 6.4135e+003

即甲产量为 23.9025, 乙产量为 62.4977, 最大利润为 6413.5

实例2 饮酒驾车血液中的酒精含量

$y = a_1 t + a_2$ $\varphi_0 = t, \varphi_1 = 1$ $\Phi \beta = y$ 无约束线性最小二乘模型

方法1: 套用法方程, 求解方程组

$$\Phi^T \Phi \beta = \Phi^T y \quad \beta = (\Phi^T \Phi)^{-1} \Phi^T y$$

方法2: 左除 $\beta = \Phi \backslash y$

方法3: 多项式拟合(polyfit命令)

`m=1; a = polyfit(t, y, m); % 降幂排列`

shili0702.m

输出结果: `a = -0.1747 4.6723`
`k = 0.1747 c0 = 106.9412`

实例3 飞机精确定位模型

$\text{Min } E(x, y) =$ 无约束非线性最小二乘模型

$$\sum_{i=1}^3 \left(\frac{\text{atan2}(x - x_i, y - y_i) - \theta_i}{\sigma_i} \right)^2 + \left(\frac{d_4 - \sqrt{(x - x_4)^2 + (y - y_4)^2}}{\sigma_4} \right)^2$$

角度需要进行预处理, 如利用atan2函数, 值域(-pi, pi) shili0703.m

飞机坐标(978.31, 723.98), 误差平方和0.6685 (<< 4)

MATLAB优化工具箱及更多的功能

- 优化工具箱主要功能
 - 无约束优化
 - 约束优化
 -
- 控制参数的设置
 - 精度控制
 - 算法选择
 - 梯度与雅可比矩阵的计算 (数值微分 / 解析表达式)
 - 初始点的选取
 -

控制精度, 观察中间结果, 控制迭代次数等

控制参数设定: `optimoptions` (旧`optimset`不推荐)

`Optimset` // 显示控制参数

`optimset optfun` // 显示optfun的控制参数

`opt=optimset` // 控制参数设为[] (即缺省值)

`opt=optimset(optfun)` // optfun控制参数设缺省值

`Opt=optimset('par1', val1, 'par2', val2, ...)`

`Opt=optimset(olddopts, 'par1', val1, ...)`

`opt=optimset(olddopts, newopts)`

`val=optimget(opt, 'par1', 'par2', ...)`

`val=optimget(opt, 'par1', 'par2', ..., default)`

主要控制参数 (对大规模/中等规模算法均有效)

`Diagnostics 'on' | {'off'}` // 是否显示诊断信息

`Display 'off' | 'iter' | 'final' | 'notify'` // 显示信息的级别

`GradObj 'on' | {'off'}` // 是否采用分析梯度

`Jacobian 'on' | {'off'}` // 采用分析Jacob阵 (用于约束优化中)

`LargeScale 'on' | {'off'}` // 是否采用大规模算法

`MaxFunEvals` 最大函数调用次数

`MaxIter` 最大迭代次数

`TolCon` 约束的控制精度 (用于约束优化中)

`TolFun` 函数值的控制精度

`TolX` 解的控制精度

更多输出: 最优值等

最一般的输出形式

`[x, f, exitflag, out, grad, hess] = fminunc(...)`

`f` 目标函数值

`exitflag` >0收敛, 0达到函数或迭代次数, <0不收敛

`Output`

`iterations` 实际迭代次数

`funcCount` 实际函数调用次数

`algorithm` 实际采用的算法

`cgiterations` 实际PCG迭代次数 (大规模算法用)

`stepsize` 最后迭代步长 (中等规模算法用)

`firstorderopt` 一阶最优条件 (梯度的范数)

`grad` 目标函数的梯度

`hess` 目标函数的Hessian矩阵

清华大学 大学数学实验

例 4 $\min \frac{x_1^2}{a} + \frac{x_2^2}{b}, \quad a=10, b=1$

用optimset控制参数选择

Exam0704.m

清华大学 大学数学实验

算法选择: **optimoptions** 中参数控制

Algorithm: 'trust-region' | 'quasi-newton'

(当前的) 缺省值为 "quasi-newton"

("trust-region" 必须要求用户提供梯度函数)

拟牛顿法 • HessUpdate = 'bfgs' (BFGS, 缺省值)
搜索方向 • HessUpdate = 'dfp' (DFP)
的选择 • HessUpdate = 'steepdesc' (最速下降方向)

注: 新版已取消搜索步长选项 (LineSearchType)

LargeScale: 'on' | 'off'

(on为缺省)

清华大学 大学数学实验

例5. $\min f(x, y) = 100(y - x^2)^2 + (1 - x)^2$

精确解: $x=y=1, f(x,y)=0$

计算结果

	搜索方向	步长搜索	最优解 x_1	最优解 x_2	最优值	目标函数调用次数
Case 1	bfgs	混合二、三次插值	9.9978e-001	9.9957e-001	4.7075e-008	1.5000e+002
Case 2	dfp		9.9950e-001	9.9899e-001	2.5440e-007	5.1300e+002
Case 3	Steepest		9.3080e-001	8.6673e-001	4.7999e-003	1.0020e+003
Case 4	bfgs	三次插值	9.9978e-001	9.9957e-001	4.7075e-008	1.5000e+002
Case 5	dfp		9.9950e-001	9.9899e-001	2.5440e-007	5.1300e+002
Case 6	Steepest		9.3080e-001	8.6673e-001	4.7999e-003	1.0020e+003

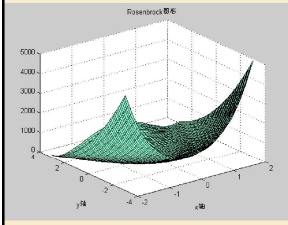
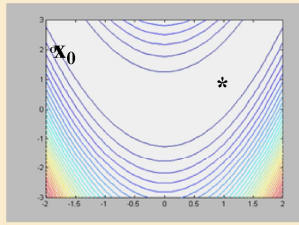
Exam0705.m

清华大学 大学数学实验

$f(x, y) = 100(y - x^2)^2 + (1 - x)^2$ 的图形

Rosenbrock 函数 (香蕉函数)

exam0705plot.m

清华大学 大学数学实验

非线性最小二乘法: $\min_{lb \leq x \leq ub} R(x) = r^T(x)r(x)$

算法选择

Algorithm: 'trust-region-reflective' (缺省) | 'Levenberg-Marquardt'

当LargeScale = 'on' 时尽可能用信赖域算法 (需要用户提供梯度函数、Jacobi矩阵)

注: 新版不提供Gauss-Newton法、步长选择

exam0705lsq.m exam0705lsq_jacob_run.m

清华大学 大学数学实验

无约束优化: 模型: $\min_x f(x), x \in R^n$

采用分析梯度

GradObj='on'

$x = \text{fminunc}(@\text{fun}, x_0, \text{opt})$

fun.m中还要有 $\nabla f(x)$

一般形式 function [f,g]=fun(x)

续例5. $\min f(x, y) = 100(y - x^2)^2 + (1 - x)^2$

算出 $\nabla f = \begin{bmatrix} -400x(y - x^2) - 2(1 - x) \\ 200(y - x^2) \end{bmatrix}$

exam0705grad_run.m

计算结果						
	搜索方向	步长搜索	最优解 x_1	最优解 x_2	最优值	目标函数调用次数
Case 1	bfgs	混合二、三次插值	9.9982e-001	9.9963e-001	3.4588e-008	5.0000e+001
Case 2	dfp		1.0002e+000	1.0003e+000	2.8158e-008	3.1800e+002
Case 3	Steepest		9.6446e-001	9.2976e-001	1.2808e-003	1.0000e+003
Case 4	bfgs	三次插值	9.9982e-001	9.9963e-001	3.4588e-008	5.0000e+001
Case 5	dfp		1.0002e+000	1.0003e+000	2.8158e-008	3.1800e+002
Case 6	Steepest		9.6446e-001	9.2976e-001	1.2808e-003	1.0000e+003

与不用分析梯度的结果比较

Case 1	bfgs	混合二、三次插值	9.9978e-001	9.9957e-001	4.7075e-008	1.5000e+002
Case 2	dfp		9.9950e-001	9.9899e-001	2.5440e-007	5.1300e+002
Case 3	Steepest		9.3080e-001	8.6673e-001	4.7999e-003	1.0020e+003
Case 4	bfgs	三次插值	9.9978e-001	9.9957e-001	4.7075e-008	1.5000e+002
Case 5	dfp		9.9950e-001	9.9899e-001	2.5440e-007	5.1300e+002
Case 6	Steepest		9.3080e-001	8.6673e-001	4.7999e-003	1.0020e+003

非线性最小二乘法:

$$r_i(x) = y_i - f(t_i, x)$$

$$r(x) = (r_1(x), \dots, r_n(x))^T$$

$$\min_{lb \leq x \leq ub} R(x) = r^T(x)r(x)$$

采用分析导数

```
[x,resnorm,res,exitf,out,lambda,jacob]=
lsqnonlin(@fun,x0,lb,ub,options)
```

输入的用法与fminunc类似，但注意：fun.m ~ r(x) 的m文件名，**Jacobian='on'** 时含有导数信息 $\nabla r(x)$

```
function [r,J] = fun(x)
```

几个值得注意的问题

梯度函数: 利用分析梯度可能改进算法的性能

精度控制: 对迭代次数有重大影响，应适当选择。

改变初始值 由一个初值出发通常得到局部最优解，如果函数存在多个局部最优，只有改变初值，对局部最优进行比较，才有可能得到全局最优解。

算法选择: BFGS公式，混合2，3次插值，一般较好。

其他算法选择: (详细用法请查阅help文档)

高度非线性、不连续时可用程序 `fminsearch(@fun,x0)`

单变量时可用程序 `fminbnd(@fun,v1,v2)`

优化工具箱的其他功能:

非线性方程(组)

单变量方程求根 (变号点): $f(x) = 0, x \in R$

```
[x,fval,exitflag,output] =
fzero(fun,x0,options)
```

多变量方程组求零点: $F(x) = 0, x \in R^n$

```
[x,fval,exitflag,output,jacobian] =
fsolve(fun,x0,options)
```

优化工具箱的其他功能:

非负最小二乘

$$\min_{x \geq 0} \|Cx - d\|_2^2$$

```
[x,resnorm,res,exitf,out,lambda]=
lsqnonneg(C,d,x0,options)
```

更一般地: 带线性约束的线性最小二乘

$$\min_{lb \leq x \leq ub} \|Cx - d\|_2^2$$

$$s.t. \quad A_1 x \leq b_1, A_2 x \leq b_2, lb \leq x \leq ub$$

```
[x,resnorm,res,exitflag,output,lambda] =
lsqlin(C,d,A1,b1,A2,b2,lb,ub,x0,options)
```

无约束优化实验内容

实验目的

- 1) 掌握 Matlab 优化工具箱的基本用法，对不同算法进行初步分析、比较。
- 2) 练习用无约束优化方法建立和求解实际问题的模型 (包括线性和非线性最小二乘拟合)。

内容

见网络学堂

